

Analyse de mouvement humain par ordinateur

Rapport de stage de Master 1

Dolbeau Tino

Juin 2026

Table des matières

1	Introduction	2
2	État de l’art	2
2.1	Soustraction de fond (<i>Background Subtraction</i>)	2
2.1.1	MOG2 — <i>Mixture of Gaussians v2</i>	2
2.1.2	ViBe — <i>Video Background Estimation</i>	3
2.2	Flux optique (<i>Optical Flow</i>)	3
2.2.1	Lucas-Kanade — flux optique <i>sparse</i> (1981)	3
2.2.2	Farneback — flux optique dense (2003)	4
2.2.3	RAFT — <i>Recurrent All-Pairs Field Transforms</i> (2020)	4
2.2.4	GMA — <i>Global Motion Aggregation</i> (2021)	4
2.2.5	MegaFlow (2025)	4
2.3	Suivi de points (<i>Point Tracking</i>)	5
2.3.1	Track4World	5
2.4	Segmentation vidéo	5
2.4.1	SAM2 — <i>Segment Anything Model v2</i> (Meta, 2024)	5
2.4.2	MatAnyone2 (2025)	6
2.5	Détection de périodicité dans le signal	6
2.5.1	Transformée de Fourier rapide (FFT)	6
2.6	Frameworks et outils	6
3	Travaux réalisés	7
3.1	Planning des missions réalisées	7
3.2	Méthodologie d’étude	7
3.3	Expérimentations et résultats	7
4	Conclusion	7
4.1	Enseignements personnels	7
4.2	Perspectives	7
4.3	Annexes	7

1 Introduction

La vision par ordinateur est un domaine de l'intelligence artificielle dont l'essor a été fulgurant au cours de la dernière décennie. Portée par la montée en puissance du deep learning et la démocratisation des données, elle a connu des avancées considérables, des réseaux convolutifs aux architectures plus récentes à base de transformers, permettant d'atteindre des performances toujours plus élevées sur des tâches autrefois inaccessibles aux machines. Ces progrès ont ouvert la voie à des applications concrètes dans des domaines aussi variés que l'analyse du mouvement humain en sport et en rééducation, la conduite autonome, le contrôle qualité industriel ou encore la surveillance et la sécurité. Au-delà de la simple analyse d'images statiques, c'est la compréhension des séquences vidéo qui concentre aujourd'hui une part croissante des travaux de recherche. L'estimation du flux optique, qui consiste à caractériser le mouvement apparent entre deux images consécutives, constitue à cet égard une brique fondamentale, permettant d'extraire une information temporelle riche à partir de données visuelles brutes.

C'est dans ce cadre que s'inscrit ce stage en computer vision. L'objectif principal de ce stage est d'explorer et d'évaluer différentes méthodes d'étude du mouvement, en particulier à travers l'estimation du flux optique, afin de mieux comprendre les forces et les limites de ces approches appliquées à des vidéos de sport et de danse. L'enjeu était ensuite d'en extraire des informations quantitatives pertinentes, telles que la fréquence d'exécution des mouvements.

2 État de l'art

Sans prétendre à l'exhaustivité, cet état de l'art présente les méthodes les plus pertinentes et les plus répandues pour l'analyse du mouvement humain en vidéo, susceptibles d'être employées dans le cadre de ce stage. Il couvre la soustraction de fond, l'estimation du flux optique, le suivi de points, la segmentation vidéo, et le traitement du signal pour l'analyse de périodicité.

2.1 Soustraction de fond (*Background Subtraction*)

La soustraction de fond est une étape de pré-traitement qui vise à isoler les pixels correspondant à un objet en mouvement par rapport à un fond supposé statique. Elle permet de réduire le bruit dans les étapes suivantes — le calcul du flux optique notamment — en masquant les zones non pertinentes.

2.1.1 MOG2 — *Mixture of Gaussians v2*

MOG2 est l'algorithme de soustraction de fond le plus utilisé en pratique. Il modélise l'intensité de chaque pixel par un mélange de gaussiennes dont les paramètres sont mis à jour à chaque image. L'idée centrale est qu'un pixel de fond peut légitimement varier (végétation, variations d'éclairage) : plutôt que de comparer à une valeur fixe, on compare à une distribution apprise. Le paramètre `varThreshold` contrôle la sensibilité : une valeur élevée ne détecte que les écarts nets, réduisant les faux positifs dus aux micro-mouvements parasites. MOG2 intègre également une phase de *warm-up* pendant laquelle le fond est estimé avant de commencer la détection effective.

Points forts : robuste aux variations lentes d'éclairage, intégré nativement à OpenCV, paramétrage simple.

Limites : temps d'initialisation nécessaire, peu adapté aux changements brusques de fond ou aux scènes très dynamiques.

2.1.2 ViBe — *Video Background Estimation*

ViBe est une alternative à MOG2 proposée par Barnich et Van Droogenbroeck [1]. Au lieu de modéliser chaque pixel par des statistiques, il maintient un échantillon de valeurs historiques pour chaque pixel. Un nouveau pixel est classifié comme fond si sa valeur est proche d'au moins N valeurs de son échantillon (critère de proximité spatiale configurable). L'algorithme est remarquablement réactif : il converge dès la deuxième image, là où MOG2 nécessite plusieurs dizaines d'images.

Points forts : initialisation quasi-instantanée, très efficace sur les objets entrant brusquement dans le champ.

Limites : moins robuste que MOG2 aux variations lentes et progressives du fond ; non intégré à OpenCV (implémentation tierce requise).

Comparaison

TABLE 1 – Comparaison des méthodes de soustraction de fond

Critère	MOG2	ViBe
Temps d'initialisation	~30 images	1–2 images
Robustesse aux variations lentes	Bonne	Faible
Réactivité aux nouveaux objets	Moyenne	Excellente
Disponibilité (OpenCV)	Native	Tierce

2.2 Flux optique (*Optical Flow*)

Le flux optique est la représentation du champ de déplacement apparent des pixels entre deux images consécutives. Pour chaque pixel (x, y) , on associe un vecteur (u, v) indiquant son déplacement estimé. C'est la brique centrale de ce projet : la magnitude de ce champ, agrégée sur les zones d'intérêt, constitue le signal analysé pour détecter la périodicité.

2.2.1 Lucas-Kanade — flux optique *sparse* (1981)

L'approche de Lucas-Kanade [5] est dite *sparse* : elle ne calcule le flux que pour un sous-ensemble de points d'intérêt détectés au préalable (par exemple avec l'algorithme de Shi-Tomasi). Pour chaque point, le déplacement est estimé par moindres carrés dans une fenêtre locale, en supposant que les pixels voisins se déplacent de façon cohérente. L'implémentation pyramidale gère les grands déplacements en traitant d'abord les basses résolutions.

Points forts : rapide, robuste sur les coins et textures, très adapté au suivi de points caractéristiques.

Limites : ne couvre pas les zones uniformes (pas de points d'intérêt détectables), sensible aux occultations.

2.2.2 Farneback — flux optique dense (2003)

L'algorithme de Farneback [2] calcule un vecteur de déplacement pour chaque pixel de l'image (*dense*). Il approxime localement chaque image par un polynôme quadratique, puis estime le déplacement en comparant les coefficients de ces polynômes entre les deux images. Il produit un tenseur de forme $(H \times W \times 2)$ représentant le champ de déplacement complet.

Points forts : couverture totale de l'image, bon compromis précision/vitesse pour des séquences à déplacements modérés.

Limites : sensible au bruit et aux grandes zones uniformes, peut produire des vecteurs incohérents sans masque de fond.

2.2.3 RAFT — *Recurrent All-Pairs Field Transforms* (2020)

RAFT [7] est une méthode d'apprentissage profond qui a établi de nouveaux scores de référence sur les benchmarks standards du flux optique (Sintel, KITTI). Son architecture repose sur trois étapes : extraction de features par CNN, construction d'un volume de corrélation 4D comparant toutes les paires de pixels entre les deux images, et raffinement itératif par un réseau GRU. RAFT est aujourd'hui la référence à partir de laquelle la plupart des méthodes récentes se comparent.

Points forts : très haute précision sur les benchmarks, bonne gestion des grands déplacements.

Limites : coût computationnel important, nécessite un GPU, non adapté au temps-réel.

2.2.4 GMA — *Global Motion Aggregation* (2021)

GMA [3] est une amélioration de RAFT qui ajoute un mécanisme d'attention globale (inspiré des Transformers) à l'étape de raffinement. L'intuition est que dans les zones occluses ou uniformes, l'information locale est insuffisante : l'attention permet de propager l'information depuis des régions contextuellement similaires ailleurs dans l'image. GMA améliore les résultats de RAFT dans les zones difficiles (occultations, grandes surfaces unies).

Points forts : meilleure précision que RAFT sur les zones uniformes et les occultations.

Limites : mêmes contraintes computationnelles que RAFT.

2.2.5 MegaFlow (2025)

MegaFlow [9] est une méthode récente basée sur une architecture *Transformer* complète, s'appuyant sur les représentations apprises par DINOv2 — un modèle de vision pré-entraîné par auto-supervision sur des milliards d'images. Elle est conçue spécifiquement pour les grands déplacements (*large displacement*), cas problématique pour RAFT et GMA. Grâce à la richesse sémantique des features DINOv2, le flux produit est nettement moins bruité sur les surfaces uniformes telles qu'un vêtement ou la peau : des pixels appartenant au même membre reçoivent des vecteurs cohérents et fluides, là où les méthodes précédentes produisent des estimations localement incohérentes.

MegaFlow produit également un score de confiance par pixel (compris entre 0 et 1), utilisable pour filtrer les vecteurs peu fiables : une valeur proche de 1 indique une correspondance sûre, proche de 0 un pixel probablement occulté ou sorti du champ.

Points forts : meilleurs scores sur les benchmarks à grands déplacements, flux visuellement cohérent sur les surfaces homogènes, score de confiance par pixel, utilisable directement sans

ré-entraînement (*zero-shot*).

Limites : modèle lourd nécessitant un GPU, non adapté au temps-réel.

Comparaison

TABLE 2 – Comparaison des méthodes de flux optique

Méthode	Type	Précision	Grands dépl.	Temps-réel
Lucas-Kanade	Sparse	Faible	Non	Oui
Farneback	Dense	Moyenne	Non	Oui
RAFT	Dense (DL)	Haute	Partielle	Non
GMA	Dense (DL)	Très haute	Partielle	Non
MegaFlow	Dense (DL)	Très haute	Oui	Non

2.3 Suivi de points (*Point Tracking*)

Le suivi de points consiste à suivre la trajectoire de pixels ou régions d'intérêt sur l'ensemble d'une vidéo, là où le flux optique ne traite que des paires d'images consécutives. C'est pertinent pour analyser des mouvements sur plusieurs cycles complets.

2.3.1 Track4World

Track4World [4] est une méthode basée sur des Transformers qui suit des points sur de longues séquences en exploitant les corrélations entre les trajectoires simultanées. Track4World est une variante dédiée aux séquences longues filmées en conditions réelles. Ces méthodes gèrent naturellement les occultations partielles en maintenant une représentation latente de chaque point même quand il disparaît temporairement du champ.

Points forts : suivi long terme, gestion des occultations, précision sur les séquences longues.

Limites : modèle lourd nécessitant un GPU, complexité d'intégration.

2.4 Segmentation vidéo

La segmentation permet d'isoler précisément le sujet d'intérêt du reste de la scène, en produisant un masque binaire par pixel, plus précis que la soustraction de fond classique.

2.4.1 SAM2 — *Segment Anything Model v2* (Meta, 2024)

SAM2 [6] est l'extension vidéo du modèle SAM. Après avoir indiqué l'objet à suivre dans une image (par un clic ou une boîte englobante), SAM2 propage ce masque de segmentation à toutes les images suivantes de la vidéo, en s'appuyant sur une mémoire temporelle. Il produit des masques précis à l'échelle du pixel, même dans des conditions d'occultation partielle.

Points forts : segmentation précise, propagation temporelle robuste, initialisation par simple interaction utilisateur.

Limites : initialisation manuelle requise, modèle lourd, non adapté au temps-réel.

2.4.2 MatAnyone2 (2025)

MatAnyone2 [8] est une méthode d'extraction de sujet vidéo qui va plus loin que la segmentation binaire : elle produit une carte d'opacité à valeurs continues entre 0 et 1, permettant de gérer proprement les zones semi-transparentes (cheveux, bords flous). Particulièrement utile lorsque la précision du masque aux bords du sujet est critique pour l'analyse.

2.5 Détection de périodicité dans le signal

Une fois le signal de magnitude du flux optique extrait, plusieurs approches classiques permettent d'en analyser la périodicité.

2.5.1 Transformée de Fourier rapide (FFT)

La FFT décompose le signal temporel en ses composantes fréquentielles. La fréquence dominante du spectre correspond directement à la fréquence de répétition du mouvement. C'est l'approche la plus rigoureuse mathématiquement, à condition que le signal soit suffisamment long et régulier pour que le spectre soit bien défini.

2.6 Frameworks et outils

TABLE 3 – Principaux outils utilisés dans le domaine

Outil	Rôle
OpenCV	Vision par ordinateur classique (flux optique, soustraction de fond)
OpenMMLab	Écosystème modulaire (MMFlow, MMPose, MMTracking)
PyTorch	Boîte à outils pour les méthodes d'apprentissage profond
HuggingFace Hub	Distribution des modèles pré-entraînés
NumPy / SciPy	Traitement du signal (FFT, filtrage)

Références

- [1] Olivier Barnich and Marc Van Droogenbroeck. Vibe : A universal background subtraction algorithm for video sequences. *IEEE Transactions on Image Processing*, 20(6) :1709–1724, 2011.
- [2] Gunnar Farneback. Two-frame motion estimation based on polynomial expansion. In *SCIA*, 2003.
- [3] Shenglong Jiang, Dylan Campbell, Yao Lu, Hongdong Li, and Richard Hartley. Learning to estimate hidden motions with global motion aggregation. In *ICCV*, 2021.
- [4] Nikita Karaev, Ignacio Rocco, Benjamin Graham, Natalia Neverova, Andrea Vedaldi, and Christian Rupprecht. Cotracker : It is better to track together. *arXiv :2307.07635*, 2023.
- [5] Bruce D Lucas and Takeo Kanade. An iterative image registration technique with an application to stereo vision. In *IJCAI*, 1981.
- [6] Nikhila Ravi et al. Sam 2 : Segment anything in images and videos. *arXiv :2408.00714*, 2024.

- [7] Zachary Teed and Jia Deng. Raft : Recurrent all-pairs field transforms for optical flow. In *ECCV*, 2020.
- [8] Jingwei Ye et al. Matanyone : Stable video matting with consistent memory propagation. *arXiv*, 2025.
- [9] Dingxi Zhang, Fangjinhua Wang, Marc Pollefeys, and Haoifei Xu. Megaflow : Zero-shot large displacement optical flow. *arXiv :2603.25739*, 2025.

3 Travaux réalisés

3.1 Planning des missions réalisées




FIGURE 1 – Diagramme de Gantt prévisionnel des tâches du projet.

3.2 Méthodologie d'étude

Afin de mener à bien ce projet, une méthodologie rigoureuse a été adoptée. Cette méthodologie est basée sur une approche itérative en cycles d'étude et est structurée en plusieurs étapes clés. Dans un premier temps, il s'agissait de définir clairement un objectif de recherche précis, puis de proposer un protocole de développement adapté à la résolution de ce problème. Ensuite, la mise en œuvre de ce protocole menait à une phase d'expérimentation aboutissant à l'obtention de résultats concrets. Pour finir ces résultats ont été analysés pour en tirer des conclusions pertinentes qui pouvait mener à des perspectives d'amélioration pour de futurs travaux et ainsi permettre de démarrer un nouveau cycle d'étude.

3.3 Expérimentations et résultats

4 Conclusion

4.1 Enseignements personnels

4.2 Perspectives

4.3 Annexes